Міністерство освіти і науки України
Державний університет «Житомирська політехніка»

Кафедра КТуМтаТ
Група ІВ-25-1

Теорія ймовірностей і математична статистика

Звіт з практичної роботи № 11–12

«Первинна обробка статистичних даних програмних систем:
варіаційний ряд, гістограма,
емпіричні числові характеристики»
Варіант 1

Перевірив: Лисенко М. С.
Виконав: Римаренко Є. О.

Житомир 2026

					ІКТР.420001.123-ПР11-12		
Змн.	Арк.	№ докум.	Підпис	Дата			
Розроб.		Римаренко Є.О.			Звіт з практичної роботи № 11–12	Літ.	Арк. 1 / Аркушів 9
Перевір.		Лисенко М. С.					
Керівник						ФІКТ, гр. ІВ-25-1	
Н. контр.							
Затверд.							

Мета та постановка завдання

Мета роботи — виконати первинну обробку статистичних даних: побудувати варіаційні ряди, ECDF, гістограми та Boxplot, обчислити числові характеристики й оцінити вплив групування та викидів. Виконано чотири блоки за варіантом 1.

Блок 1 Обробка незгрупованої вибірки

1.1 Математична модель

Дані — 20 затримок функції в мілісекундах. Для унікальних значень x_i підраховано частоти n_i та $w_i = n_i/n$. Порядок вимірів на оцінки не впливає; усі повторення враховуються.

$$\bar{x} = \frac{1}{n}\sum x_i; \quad s^2 = \frac{1}{n}\sum (x_i - \bar{x})^2$$

$$S^2 = \frac{n}{n-1}s^2; \quad S = \sqrt{S^2}; \quad V = \frac{S}{\bar{x}} \cdot 100\%$$

Медіана — півсума 10-го й 11-го елементів, мода — найчастіше значення, розмах $R = x_{(20)} - x_{(1)}$. За визначенням методички $F^*_n(x) = n_x/n$, де n_x рахує лише значення, строго менші за x. Тому в точці стрибка значення функції належить нижній сходинці.

1.2 Програмна реалізація

Файл src/block1.py. sorted упорядковує вибірку, Counter підраховує повторення. Функція characteristics обчислює обидві дисперсії; виправлене стандартне відхилення береться з дільником n−1.

```
ordered = sorted(X_RAW)
counts = Counter(ordered)
mean = sum(data) / n
squared_sum = 0.0
for value in data:
    squared_sum += (value - mean) ** 2
variance = squared_sum / n
corrected_variance = squared_sum / (n - 1)
```

1.3 Результати

Ранжований ряд: 18,2; 18,2; 18,2; 19,8; 21,0; 21,0; 21,0; 21,0; 23,4; 23,4; 23,4; 23,4; 23,4; 25,1; 25,1; 25,1; 27,8; 27,8; 29,5; 31,0.

Таблиця 1 — Статистичний розподіл затримок

x_i, мс	n_i	w_i
18,2	3	0,15
19,8	1	0,05
21,0	4	0,20
23,4	5	0,25
25,1	3	0,15
27,8	2	0,10
29,5	1	0,05
31,0	1	0,05

Таблиця 2 — Числові характеристики заданої вибірки

Характеристика	**Значення**
Середнє $\bar{x}$, мс	23,340000
Вибіркова дисперсія s^2, мс²	12,970400
Виправлена дисперсія S^2, мс²	13,653053
Виправлене S, мс	3,695004
Медіана / мода, мс	23,4 / 23,4
Розмах R, мс	12,8
Коефіцієнт варіації V, %	15,831207

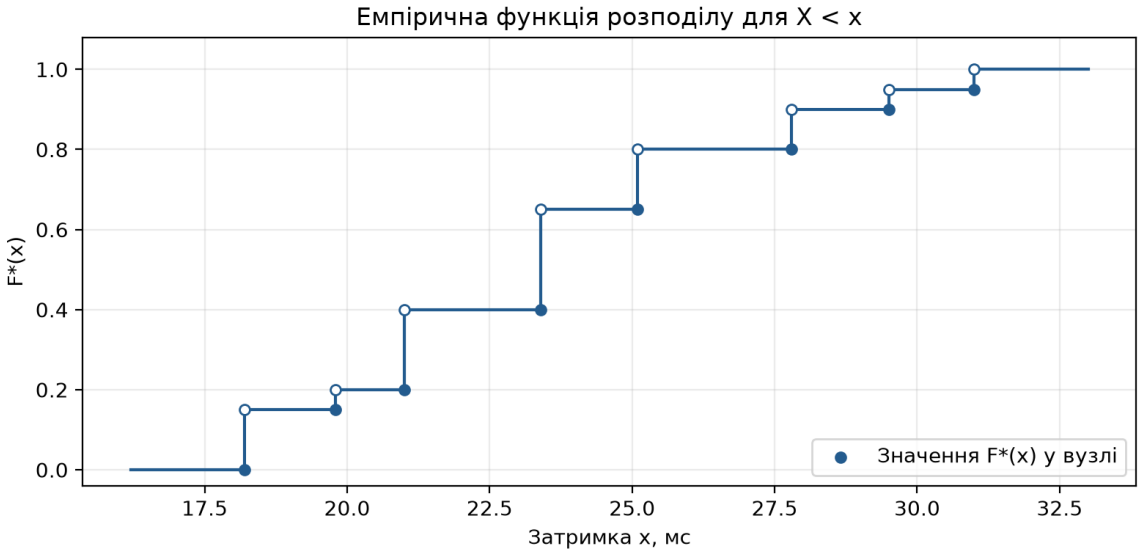


Рисунок 1 — Емпірична функція розподілу заданих затримок

Суми частот дорівнюють 20 та 1 відповідно. Найчастіше значення — 23,4 мс, воно трапляється п’ять разів. Наприклад, $F^*_n(23{,}4) = 8/20 = 0{,}40$, а одразу праворуч від 23,4 мс — 13/20 = 0,65. Коефіцієнт варіації 15,83% вказує на помірне розсіювання.

Блок 2 Інтервальне групування затримок

2.1 Математична модель

Варіант 1: затримка мікросервісу A. Використано суміш 95% N(150, 20²) мс і 5% U(200, 300) мс. Згенеровано рівно 190 звичайних вимірів та 10 сплесків, після чого їх перемішано. Це фіксована частка компонентів, а не випадкова біноміальна кількість сплесків. Загальний обсяг n = 200, np.random.seed(42).

$$k = 1 + \lfloor 3{,}322 \cdot log_{10}200 \rfloor = 8; \quad h = \frac{x_{\max} - x_{\min}}{8}$$

$$w_i = n_i/n; \quad p_i = w_i/h; \quad x_i = (a_i + a_{i+1})/2$$

$$\bar{x}(grp) = \frac{1}{n}\sum n_i x_i; \quad S^2(grp) = \frac{1}{n-1}\sum n_i (x_i - \bar{x}(grp))^2$$

Інтервали мають вигляд $[a_i, a_{i+1})$, останній включає також праву межу. Інакше максимум вибірки було б втрачено. Похибки групування — модулі різниць згрупованої та незгрупованої оцінок; відносні похибки діляться на відповідні незгруповані оцінки.

2.2 Програмна реалізація

Файл src/block2.py. generate_sample формує відтворювані дані. np.histogram підраховує частоти за неокругленими межами. Для згрупованих оцінок усі значення інтервалу замінюються його серединою.

```
np.random.seed(42)
regular = np.random.normal(150, 20, 190)
spikes = np.random.uniform(200, 300, 10)
data = np.concatenate((regular, spikes))
np.random.shuffle(data)
counts, _ = np.histogram(data, bins=edges)
midpoints = (edges[:-1] + edges[1:]) / 2
weights = counts / n
density = weights / h
```

2.3 Результати

Мінімум — 97,605098 мс, максимум — 299,005385 мс. Крок h = 25,175036 мс. Межі в таблиці округлені лише для відображення.

Таблиця 3 — Інтервальний розподіл затримок

Інтервал, мс	Середина, мс	n_i	w_i	p_i, 1/мс
[97,605; 122,780)	110,193	16	0,080	0,003178
[122,780; 147,955)	135,368	72	0,360	0,014300
[147,955; 173,130)	160,543	83	0,415	0,016485
[173,130; 198,305)	185,718	17	0,085	0,003376
[198,305; 223,480)	210,893	4	0,020	0,000794
[223,480; 248,655)	236,068	1	0,005	0,000199
[248,655; 273,830)	261,243	4	0,020	0,000794
[273,830; 299,005]	286,418	3	0,015	0,000596

Таблиця 4 — Похибка групування

Оцінка	За даними	Згрупована	Абс. похибка	Відн., %
$\bar{x}$, мс	154,771814	154,878305	0,106490	0,068805
S^2, мс²	943,748163	977,346652	33,598489	3,560112

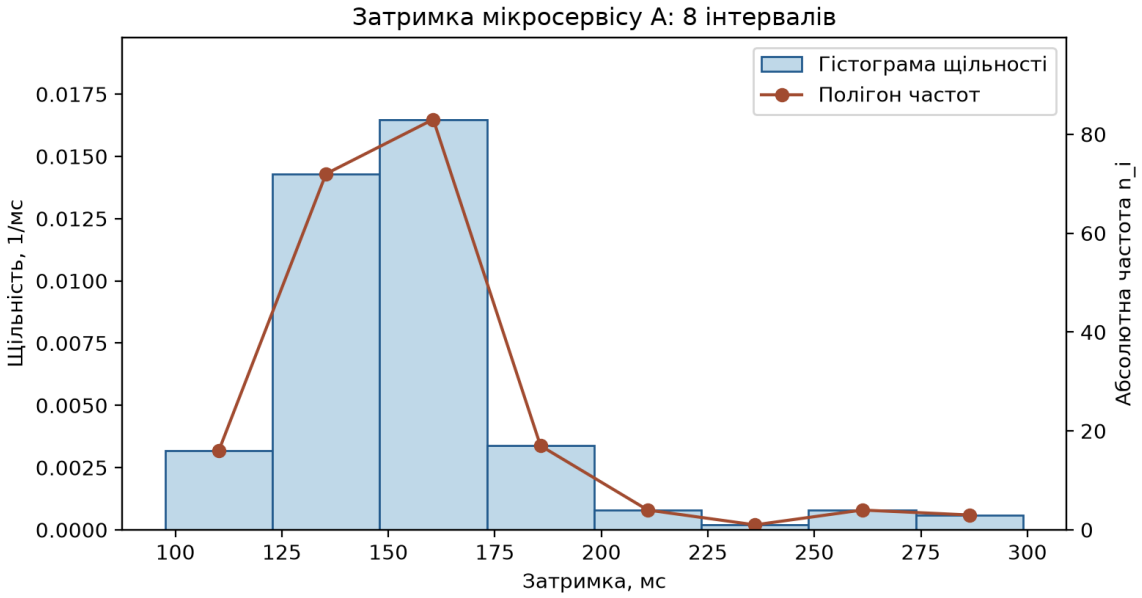


Рисунок 2 — Гістограма щільності та полігон абсолютних частот

Сума $n_i = 200$, сума $w_i = 1$, площа гістограми $\sum p_i h = 1$. Найбільша частота — 83 виміри — припадає на інтервал [147,955; 173,130) мс. Похибка середнього становить 0,0688%, дисперсії — 3,5601%. Групування тут сильніше змінює оцінку розсіювання. На рисунку щільність і кількість вимірів показано на різних підписаних осях.

Блок 3 Виявлення та фільтрація викидів

3.1 Математична модель

До початкової вибірки блока 2 додано 10 аномальних затримок. Середнє $\bar{x}$ та S у формулі нижче обчислено до забруднення. Кожне додане значення строго перевищує $\bar{x}$ + 5S; обсяг спотвореної вибірки — 210.

$$z_j = \bar{x} + (5 + j/2)S,\ j = 1, \ldots, 10$$

$$IQR = Q_3 - Q_1;\ \ L = Q_1 - 1{,}5IQR;\ \ U = Q_3 + 1{,}5IQR$$

Квартилі Q_1 та Q_3 — 25-й і 75-й перцентилі спотвореної вибірки. Використано лінійну інтерполяцію: для частки p позиція в упорядкованому списку дорівнює (n−1)p за нумерації від нуля. Значення поза [L; U] вилучаються одним проходом; граничні значення залишаються.

3.2 Програмна реалізація

Файл src/block3.py. generate_sample повторює саме дані блока 2. Маска залишає виміри в межах IQR. Окремо підраховано, скільки вилучених значень належать початковій вибірці та скільки було додано.

```
threshold = original_stats['mean'] + 5 * original_stats['std']
anomalies = threshold + np.arange(1, 11) * original_stats['std'] / 2
dirty = np.concatenate((original, anomalies))
q1, q3 = np.percentile(dirty, [25, 75], method='linear')
iqr = q3 - q1
lower = q1 - 1.5 * iqr
upper = q3 + 1.5 * iqr
clean = dirty[(dirty >= lower) & (dirty <= upper)]
```

3.3 Результати

Поріг додавання $\bar{x}$ + 5S = 308,374236 мс. Додані значення: 323,734; 339,095; 354,455; 369,815; 385,175; 400,536; 415,896; 431,256; 446,616; 461,977 мс.

Таблиця 5 — Квартилі та межі спотвореної вибірки

Q_1, мс	Q_3, мс	IQR, мс	L, мс	U, мс
138,158931	166,265387	28,106456	95,999246	208,425072

Таблиця 6 — Характеристики до та після фільтрації

Вибірка	n	$\bar{x}$, мс	S, мс	Медіана, мс
Початкова	200	154,771814	30,720484	151,360912

Вибірка	n	x̄, мс	S, мс	Медіана, мс
Спотворена	210	166,109136	59,788987	152,105740
Очищена	190	149,339365	18,844306	149,599889

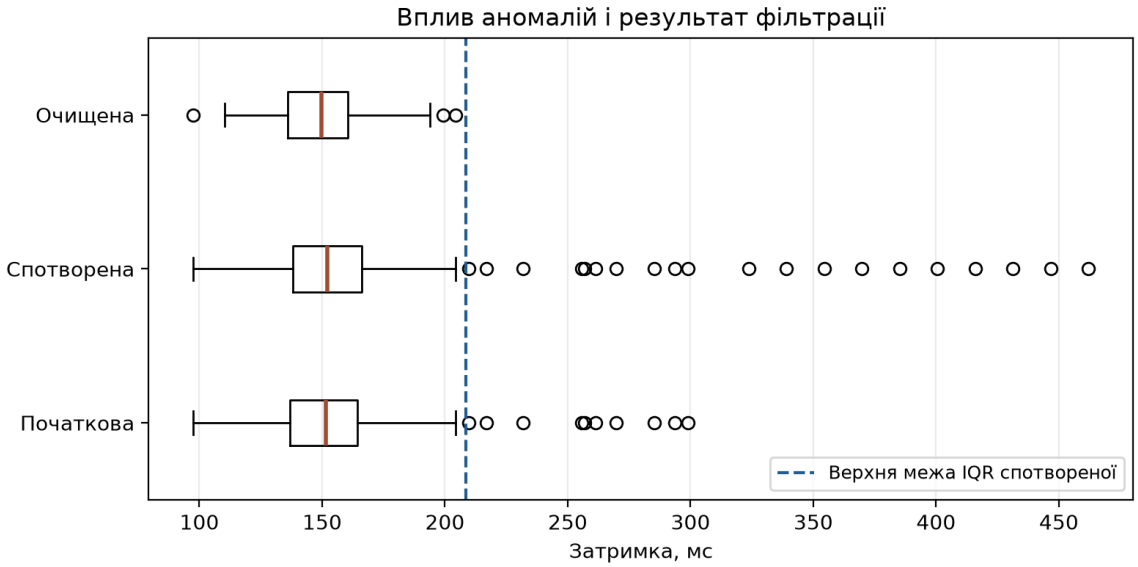


Рисунок 3 — Порівняння початкових, спотворених і очищених затримок

Вилучено 20 значень: усі 10 доданих аномалій і 10 сплесків із початкової вибірки. Очищення не повертає початкові 200 вимірів: залишилося 190. Правило IQR позначає незвичні значення, але саме по собі не доводить, що вимір помилковий. Реальні сплески продуктивності можуть бути змістовними.

Після додавання аномалій середнє зросло на 11,337322 мс, а медіана — лише на 0,744828 мс. Отже, медіана в цьому експерименті стійкіша. На кожному Boxplot квартилі та вуса обчислені для його власної вибірки. Тому в очищеній вибірці можуть знову з’явитися позначки викидів; повторна фільтрація не виконувалася. Пунктир показує верхню межу саме спотвореної вибірки.

Блок 4 Аналіз завантаження CPU

4.1 Математична модель

Для варіанта 1 потрібно дослідити 300 вимірів завантаження CPU. Методичка не надає самих логів і параметрів їх генерації. Прийнято навчальну модель незалежних U(20; 90)%, seed = 43. Це модельні значення, а не фактичні показники комп’ютера. Порядок вимірів не використовується для аналізу часової залежності.

$$\bar{x} = \frac{1}{n}\sum x_i; \quad S = \sqrt{[(1/(n-1))\sum(x_i - \bar{x})^2]}; \quad V = \frac{S}{\bar{x}} \cdot 100\%$$

За критеріями методички V < 10% означає незначне розсіювання, V > 33% — неоднорідність. Для гістограми використано правило Стерджеса: k = 1 + ⌊3,322·log₁₀300⌋ = 9. Для обраної рівномірної моделі теоретично M[X] = 55%, σ = 70/√12 ≈ 20,2073 процентного пункта.

4.2 Програмна реалізація

Файл src/block4.py. Згенеровано 300 модельних вимірів, обчислено характеристики тією самою функцією, що й у першому блоці. На гістограмі окремо позначено середнє та медіану.

```
np.random.seed(43)
cpu = np.random.uniform(20, 90, 300)
stats = characteristics(cpu)
k = 1 + int(3.322 * np.log10(len(cpu)))
if stats['cv'] > 33:
    conclusion = 'Навантаження неоднорідне: V > 33%.'
```

4.3 Результати

Таблиця 7 — Характеристики модельного завантаження CPU

n	x̄, %	S, п.п.	Медіана, %	V, %
300	55,650836	20,786340	55,868697	37,351354

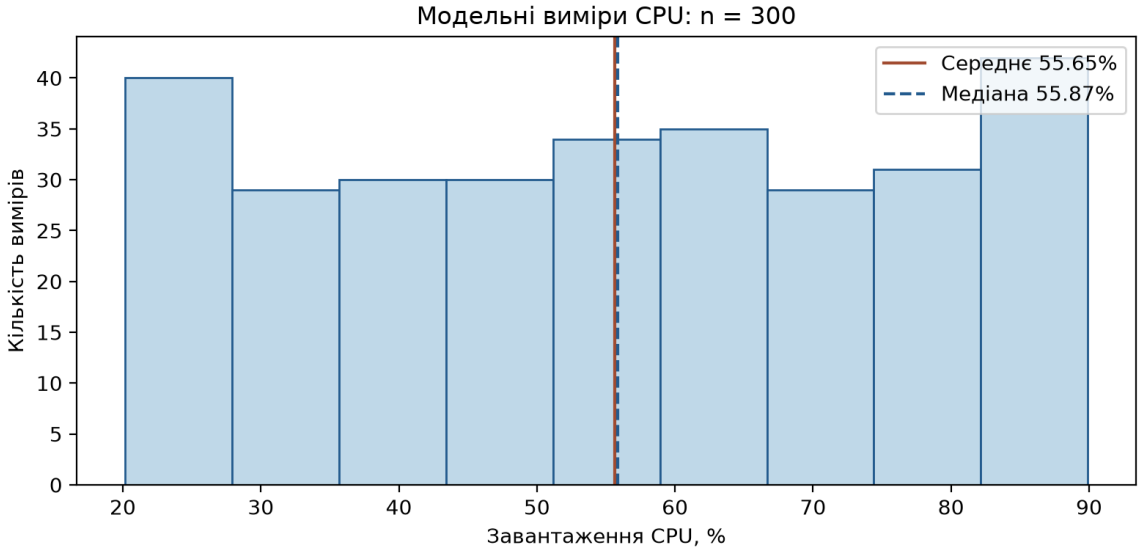


Рисунок 4 — Гістограма 300 модельних вимірів завантаження CPU

Для модельної вибірки V = 37,351354% > 33%, тому навантаження неоднорідне за прийнятим критерієм. Середнє 55,650836% і медіана 55,868697% близькі. Стандартне відхилення 20,786340 п.п. характеризує помітні коливання. Цей висновок стосується обраної моделі й не є оцінкою реального сервера.

Висновки

Побудовано дискретний та інтервальний варіаційні ряди, ECDF, гістограми, полігон і Boxplot. Для заданих 20 затримок середнє становить 23,34 мс, медіана й мода — 23,4 мс. Групування 200 затримок дало невелику похибку середнього — 0,106490 мс, але помітнішу відносну похибку дисперсії — 3,5601%.

Додані аномалії значно сильніше змінили середнє, ніж медіану. Після IQR-фільтрації залишилося 190 вимірів; разом із доданими аномаліями вилучено початкові сплески. Для 300 модельних значень CPU отримано V = 37,35%, що відповідає неоднорідному навантаженню.

Код і джерела

Код програми: pr6-primary-statistical-analysis, файли src/block1.py — src/block4.py та src/main.py. Залежності: NumPy і Matplotlib. Усі блоки перевірено окремо та спільним запуском у Windows, Python 3.14.7, NumPy 2.5.2, Matplotlib 3.11.2.

https://github.com/gjn9429-oss/pr6-primary-statistical-analysis

Джерело завдань: «Практична робота № 11–12. Первинна обробка статистичних даних програмних систем» — блок 1, пп. 1–4, с. 2–3; блок 2, пп. 1–6 і варіант 1, с. 3; блок 3, пп. 1–5, с. 4; блок 4, варіант 1, с. 4. Критерії оцінювання: програма дисципліни, розділ 8.4, с. 12.